

华南师范大学

人工智能学院

基于代理模型与改进粒子群算法的
F1 赛车气动稳定性优化研究

《计算智能》课程设计

姓名：陈新安

学号：202440012028

姓名：郑骏远

学号：202440012047

2025-2026 学年第二学期

摘要

随着 2022 年 FIA 引入“地面效应”空气动力学规则, F1 赛车的海豚跳 (Porpoising) 现象成为工程设计中的关键挑战。传统 CFD 仿真在规则限制下难以高效覆盖大规模参数空间, 亟需低成本、高效率的替代方法。

本文基于 Kaggle 公开的 F1 气动稳定性数据集 (约 15 万样本), 构建了一套数据驱动的代理优化框架。首先通过 6 种机器学习模型的系统对比, 选定 XGBoost 与 DeepEnsemble 作为代理模型, 分别实现 $R^2 = 0.9999$ 和 $R^2 = 0.9995$ 的预测精度。在此基础上, 提出风险敏感粒子群优化算法 (Risk-Sensitive PSO), 以 $\mu(x) - \lambda\sigma(x)$ 为适应度函数, 有效抑制代理模型在分布外 (OOD) 区域的幻觉行为。进一步通过主动学习闭环实现模型精炼, 将 MSE 从 0.3272 降至 0.1444 (降低 55.9%), 收敛速度提升 2.1 倍。

在多场景优化模块中, 针对 Monza 高速、Monaco 高下压力、均衡设置和湿地四种典型 F1 工况, 采用多目标加权适应度函数进行 Pareto 前沿搜索, 并通过 SHAP、排列重要性、约束灵敏度分析和 Landscape Diagnosis 对最优解进行了系统性的可解释性验证。Porpoising 风险分析模块通过一阶梯度热力图和二阶 Hessian 曲率分析, 刻画了不同工况下的海豚跳风险空间分布。

实验结果表明: 代理模型 R^2 达到 0.9999, 远超理想目标 (≥ 0.92); PSO 平均收敛代数为 27.9 代 (最优目标 ≤ 50); 单次寻优耗时约 83ms; 消融实验验证了风险敏感适应度的 OOD 保护功能, 以及多目标优化相较单目标优化的区分度提升 (从 0.1% 到 20% 以上)。

研究工作形成了一套完整的“数据预处理—代理建模—风险感知优化—可解释性验证”技术路线, 为 F1 赛车气动参数的高效求解提供了可量化的方法论支撑。

关键词: 代理模型; 粒子群优化; F1 赛车; 气动稳定性; 海豚跳; 多目标优化; 可解释性分析

目录

1	研究背景	1
1.1	问题定义	1
1.2	研究目标	1
1.3	研究意义	2
2	数据分析与预处理	2
2.1	数据集来源与结构	2
2.2	描述性统计分析	3
2.3	数据不平衡分析	3
2.4	数据预处理流程	4
2.5	探索性数据分析	4
3	代理模型构建	5
3.1	候选模型谱系	5
3.2	训练配置	6
3.3	评价指标	7
3.4	模型对比结果	7
3.5	模型选择策略	8
3.6	低稳定性样本的预测能力评估	8
4	粒子群优化算法	9
4.1	标准 PSO	9
4.2	自适应惯性权重改进	10
4.3	风险敏感适应度函数（创新点）	10
4.4	PSO 配置总结	11
4.5	PSO 收敛分析	11
4.6	密度惩罚机制	13
5	主动学习迭代精炼	13
5.1	闭环机制	13
5.2	浅层一轮后处理精炼	13
5.3	候选解特征分析	14
5.4	PSO 收敛行为改善	15
5.5	小结	15

6	多场景优化与可解释性	15
6.1	场景定义	15
6.2	多目标适应度函数 (v2)	16
6.3	多场景寻优结果	17
6.4	Pareto 前沿分析	18
6.5	场景对比: 平行坐标图	18
6.6	SHAP 全局可解释性	19
6.7	排列重要性验证	20
6.8	约束灵敏度分析	20
6.9	多目标收敛分析	21
6.10	景观多峰性验证	22
6.11	小结	22
7	Porpoising 风险分析	23
7.1	问题背景	23
7.2	一阶梯度风险热力图	23
7.3	二阶 Hessian 曲率分析	25
7.4	多场景最优解与风险叠加	26
7.5	小结	26
8	实验结果与分析	26
8.1	对比实验	26
8.2	消融实验	28
8.3	模型选择消融	29
8.4	鲁棒性实验	29
8.4.1	随机种子鲁棒性	29
8.4.2	模型输出噪声鲁棒性	29
8.4.3	超参数敏感性	30
8.5	消融实验综合结果	30
8.6	优化景观诊断	31
8.6.1	翼角敏感性分析	31
8.6.2	Speed $\times$ Wing 梯度分析	32
8.6.3	代理模型饱和现象的完整证据链	33
8.6.4	数据结构根源诊断	33
8.7	整体结论	34

9 结论与展望	34
9.1 主要贡献	34
9.2 量化指标达成情况	35
9.3 不足与讨论	36
9.4 未来工作	36

1 研究背景

1.1 问题定义

F1 赛车的空气动力学设计高度依赖计算流体力学 (CFD) 与风洞实验。2022 年 FIA 引入”地面效应”规则后，赛车设计面临全新的核心矛盾：

1. **规则约束**：FIA 的空气动力学测试限制 (ATR) 对 CFD 仿真时长和计算资源实施严格配额，传统高精度仿真在有限周期内难以覆盖大规模参数空间；
2. **瞬态非线性**：“海豚跳” (Porpoising) 涉及车速、翼角、DRS 状态等多参数的共振耦合，传统方法难以捕捉其强非线性特性；
3. **数据不平衡**：公开数据集中高稳定性样本占绝对多数 (86.02%)，低稳定性样本稀缺，给机器学习建模带来偏置风险。

1.2 研究目标

本研究旨在构建一套**数据驱动的代理模型 + 智能优化**框架，设 $x = (\text{speed}, \text{wing_angle}, \text{drs}, \text{downforce}) \in \mathbb{R}^5$ 为赛车工况参数， $y = f(x) \in [0, 100]$ 为气动稳定性评分。

核心目标分为以下三个层次：

目标一：代理模型构建

建立从 5 维输入到稳定性评分的回归映射 $\hat{f}(x)$ 。要求：

- 预测精度 $R^2 \geq 0.85$ (最低) / ≥ 0.92 (理想)
- 推理延迟 $\leq 10\text{ms}$ ，支撑 PSO 高频调用
- 对比不少于 4 种模型，形成完整谱系评估

目标二：风险感知参数寻优

在代理模型之上，求解约束优化问题：

$$x^* = \arg \max_{x \in \mathcal{X}} [\mu(x) - \lambda \cdot \sigma(x) - P_{\text{scenario}}(x)] \quad (1)$$

其中：

- $\mu(x)$ 为深度集成模型 (DeepEnsemble) 对稳定性的预测均值；
- $\sigma(x)$ 为集成成员间的预测标准差 (不确定性)；
- λ 为风险厌恶系数；

- $P_{\text{scenario}}(x)$ 为场景相关的软约束惩罚项。

该公式是本文的核心创新——通过显式惩罚预测不确定性，使 PSO 在搜索过程中自然避开代理模型不可靠的分布外（OOD）区域。

目标三：多场景优化与可解释性

定义 4 组典型 F1 赛道工况，在不同约束和权重向量下运行多目标 PSO 寻优，并通过 SHAP、排列重要性、约束灵敏度分析和 Landscape Diagnosis 对最优解进行可解释性验证，确保优化结果的物理合理性和方法论可信度。

1.3 研究意义

本课题的实践意义在于：（1）为 F1 车队在规则限制下提供一种低成本的气动参数快速筛选工具；（2）通过风险敏感机制解决代理模型在 OOD 区域的可靠性问题，提升工程决策的鲁棒性；（3）系统性的可解释性分析为数据驱动优化结果提供了透明、可追溯的验证路径。

在方法论层面，本课题构建的”代理建模—不确定性感知优化—主动学习精炼—多维可解释性”技术闭环，可迁移至航空航天、船舶水动力学等具有类似”高成本仿真 + 大规模参数空间 + 数据不平衡”特征的工程优化场景。

2 数据分析与预处理

2.1 数据集来源与结构

数据来源于 Kaggle 公开数据集 *F1 Aerodynamic Stability and Porpoising (150k Samples)*。原始数据包含约 15 万条样本，经数据清洗后保留 104,999 条有效样本，包含 5 个输入特征和 1 个目标变量。

表 1: 数据字段描述

字段	类型	描述
speed_kmh	float64	赛车时速 (km/h)
wing_angle_deg	float64	前翼角度 (°)
drs_active	int (0/1)	DRS 激活状态
downforce_n	float64	下压力 (N)
drag_n	float64	空气阻力 (N)
stability_index	float64	气动稳定性评分 (0-100)

2.2 描述性统计分析

表 2: 各特征描述性统计

特征	均值	标准差	最小值	中位数	最大值	偏度
speed_kmh	232.5	76.5	100.0	232.7	365.0	-0.00
wing_angle_deg	20.0	8.7	5.0	20.0	35.0	0.00
drs_active	0.30	0.46	0.0	0.0	1.0	0.88
downforce_n	2392.4	1844.6	105.3	1842.5	8969.2	1.07
drag_n	166.1	106.5	18.1	145.6	515.9	0.67
stability_index	91.3	24.8	0.0	100.0	100.0	-2.90

从统计表中可观察到：speed_kmh 和 wing_angle_deg 近似对称分布（偏度 ≈ 0 ）；downforce_n 和 drag_n 呈右偏分布（偏度分别为 1.07 和 0.67），高值样本相对较少；stability_index 呈严重左偏分布（偏度 = -2.90），大部分样本集中在高稳定性区域。

2.3 数据不平衡分析

稳定性分布存在严重的不平衡现象：

表 3: 稳定性分级分布

稳定性等级	评分范围	样本数	占比
严重不稳定 (severe)	[0, 30)	9,563	6.38%
中度不稳定 (moderate)	[30, 60)	4,513	3.01%
轻度不稳定 (mild)	[60, 95)	6,895	4.60%
稳定 (stable)	[95, 101)	129,028	86.02%

稳定样本与不稳定样本的比例约为 6.15:1，构成了典型的类不平衡问题。高稳定性样本（ ≥ 95 ）占比 86.02%，可能导致模型过度依赖数据量占优的稳定样本特征分布，在低稳定性区域产生预测偏差。

针对不平衡问题，采用类平衡加权策略：

$$w_i = \frac{N}{K \cdot n_i} \quad (2)$$

其中 N 为总样本数， $K = 4$ 为分级数， n_i 为第 i 级的样本数。severe 级权重 3.92，moderate 级权重 8.31，mild 级权重 5.44，stable 级权重 0.29。该权重策略在模型训练损失函数中赋予低稳定性样本更高的优化优先级。

2.4 数据预处理流程

预处理包括以下步骤：

1. **数据清洗**：检测并剔除缺失值和格式异常记录；
2. **特征归一化**：对连续特征采用 StandardScaler （用于 XGBoost/Ridge/Random Forest）和 MinMaxScaler （用于神经网络模型）两种归一化策略；
3. **数据集划分**：按 7:1.5:1.5 比例划分为训练集、验证集和测试集 (random_state=42)。

2.5 探索性数据分析




图 1：各特征分布及稳定性评分分布直方图

图1展示了 6 个变量的分布情况。stability_index 呈现典型的”天花板效应”——绝大多数样本集中在满分（100）附近，这是后续代理模型在高稳定性区输出饱和的根本原因。




图 2: 特征间相关系数矩阵

图2的相关系数矩阵揭示了关键的数据结构特征：downforce_n 与 stability_index 的相关性最强 (Pearson $r = -0.773$, Spearman $\rho = -0.617$)；downforce_n 与 drag_n 之间存在极强正相关 ($r = 0.895$)；wing_angle_deg 与 stability_index 的 $r = -0.384$ ，但控制 downforce_n 后的偏相关系数仅为 0.06，表明翼角的影响几乎完全通过下压力实现中介传递。

值得注意的是关键特征间耦合：speed_kmh 与 drag_n 的 $r = 0.924$ ，speed_kmh 与 downforce_n 的 $r = 0.768$ ，这些强耦合关系解释了为什么高速工况下赛车同时面临高阻力和高下压力，构成了气动设计的经典 tradeoff。

3 代理模型构建

3.1 候选模型谱系

为建立赛车工况参数到稳定性评分的回归映射，从传统回归到深度学习构建了 6 个模型的完整对比谱系：

1. **M1 Ridge** (Ridge 回归)：线性基准模型，提供模型复杂度下界的参考；

2. **M2 Random Forest** (随机森林): 集成学习的经典代表, 对噪声和过拟合有一定鲁棒性;
3. **M3 XGBoost**: 梯度提升决策树, 以其在表格数据上的卓越表现著称;
4. **M4 MLP** (多层感知机): 3 隐藏层 (128-256-128-64) 的前馈神经网络, 配备 ReLU 激活和 Dropout 正则化;
5. **M5 TabNet**: 基于注意力机制的可解释深度学习模型, 专为表格数据设计;
6. **M6 DeepEnsemble** (深度集成): 3 个独立 MLP 的集成, 仅改变初始化种子和数据 shuffle。输出预测均值 $\mu(x)$ 和标准差 $\sigma(x)$, 为风险敏感 PSO 提供不确定性估计。

3.2 训练配置

MLP/DeepEnsemble 采用以下训练配置:

- 优化器: Adam ($\text{lr}=1 \times 10^{-3}$, $\text{weight_decay}=1 \times 10^{-5}$)
- 损失函数: 加权 MSE (低稳定性样本权重加倍)
- 正则化: Dropout ($p=0.2$), Early Stopping ($\text{patience}=20$)
- 批量大小: 256
- 最大训练轮数: 500

为应对数据不平衡问题, 在损失函数中引入类平衡权重, 使模型对低稳定性样本的预测误差给予更高惩罚。

XGBoost 采用以下配置:

- 树数量: 300
- 最大深度: 6
- 学习率: 0.1
- 子采样率: 0.8
- 列采样率: 0.8

3.3 评价指标

采用以下指标评估各模型性能：

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5)$$

3.4 模型对比结果

表 4: 6 模型性能对比

模型	R^2	MSE	MAE	RMSE	延迟 (ms)
M1 Ridge	0.6330	225.0046	12.3392	15.0002	0.034
M2 RandomForest	1.0000	0.0000	0.0006	0.0025	37.073
M3 XGBoost	0.9999	0.0312	0.0350	0.1767	0.242
M4 MLP	0.9994	0.3897	0.3882	0.6243	0.403
M5 TabNet	0.9997	0.2002	0.3602	0.4475	7.847
M6 DeepEnsemble	0.9995	0.3272	0.2712	0.5720	1.230




图 3: 6 模型性能对比可视化 (R^2 、MSE、MAE、延迟)

XGBoost (M3) 在所有指标上均表现最优： $R^2 = 0.9999$ ， $\text{MSE} = 0.0312$ ， $\text{MAE} = 0.0350$ ，推理延迟仅 0.242ms，完美适合 PSO 高频调用场景。DeepEnsemble (M6) 虽然精度略低于 XGBoost ($R^2 = 0.9995$ ， $\text{MSE} = 0.3272$)，但其不确定性估计能力 $\sigma(x)$ 是风险敏感优化的关键组件。

Random Forest (M2) 在测试集上达到 $R^2 = 1.0$ ，但 37ms 的推理延迟不适合 PSO 高频调用（每代 50 粒子 $\times$ 80 迭代 $\times$ 37ms $\approx$ 148s），且存在过拟合风险。Ridge (M1) 作为线性基准 R^2 仅 0.633，验证了该问题的强非线性特征。




图 4: 神经网络模型训练损失曲线

图4展示了 MLP 和 DeepEnsemble 的训练/验证损失随 Epoch 的变化。MLP 验证集 MSE 收敛至约 0.39，DeepEnsemble 的 3 个成员分别收敛至相近水平。Early Stopping 在约 200 轮时触发，防止了过拟合。

3.5 模型选择策略

基于精度-效率权衡：

- **可解释性分析** (SHAP、排列重要性)：使用 XGBoost (M3)，因其 TreeExplainer 精确快速；
- **PSO 寻优**：使用 DeepEnsemble (M6)，以提供 $\mu(x)$ 和 $\sigma(x)$ 用于风险敏感适应度计算。

3.6 低稳定性样本的预测能力评估

考虑到数据不平衡，进一步评估各模型在低稳定性样本 (stability_index < 95) 上的表现：

表 5: 低稳定性样本上的模型表现

模型	R^2_{low}	MSE_{low}
M1 Ridge	0.7815	239.0342
M2 RandomForest	1.0000	0.0000
M3 XGBoost	1.0000	0.0371
M4 MLP	0.9989	1.1690
M5 TabNet	0.9998	0.1725
M6 DeepEnsemble	0.9989	1.1494

XGBoost 和 Random Forest 在低稳定性样本上继续保持极高精度，MLP 和 Deep-Ensemble 略有下降但仍在可接受范围 ($R^2_{\text{low}} \geq 0.9989$)。这表明加权损失函数策略有效缓解了不平衡问题对模型拟合的负面影响。

4 粒子群优化算法

4.1 标准 PSO

粒子群优化 (Particle Swarm Optimization, PSO) 由 Kennedy 和 Eberhart 于 1995 年提出，是一种基于群体智能的元启发式优化算法。在标准 PSO 中，每个粒子维护自身的历史最优解 p_i 和全局最优解 g ，通过以下公式更新速度和位置：

$$v_i^{t+1} = wv_i^t + c_1r_1(p_i - x_i^t) + c_2r_2(g - x_i^t) \quad (6)$$

$$x_i^{t+1} = x_i^t + v_i^{t+1} \quad (7)$$

其中：

- v_i^t : 粒子 i 在第 t 代的速度向量；
- x_i^t : 粒子 i 在第 t 代的位置向量；
- w : 惯性权重，控制搜索的探索-利用平衡；
- c_1, c_2 : 个体学习和群体学习因子（标准值 1.5–2.0）；
- r_1, r_2 : $[0, 1]$ 上的随机数，引入随机扰动。

4.2 自适应惯性权重改进

标准 PSO 使用固定惯性权重 w ，难以在探索（大 w ）和利用（小 w ）之间自适应切换。本课题引入自适应惯性权重策略：

$$w(t) = w_{\max} - (w_{\max} - w_{\min}) \cdot \frac{t}{T_{\max}} \quad (8)$$

其中 $w_{\max} = 0.9$, $w_{\min} = 0.4$, t 为当前迭代数, $T_{\max}$ 为最大迭代数。线性递减策略使 PSO 在早期维持较强的全局探索能力, 后期集中于局部精细搜索。

4.3 风险敏感适应度函数（创新点）

本研究提出**风险敏感适应度函数**, 利用 DeepEnsemble 的不确定性估计能力, 将 PSO 的标准目标函数扩展为：

$$\text{Fitness}(x) = \mu(x) - \lambda \cdot \sigma(x) - P_{\text{scenario}}(x) \quad (9)$$

该公式同时解决三个关键问题：

1. **OOD 防护**：当 PSO 粒子进入训练数据稀疏的分布外（OOD）区域时，DeepEnsemble 的 $\sigma(x)$ 显著增大， $\lambda\sigma(x)$ 项产生惩罚，使粒子自然返回可靠区域；
2. **不平衡缓解**：低稳定性样本在原数据集中的稀疏性导致代理模型对低稳定性预测范围的不确定性更高， $\sigma(x)$ 惩罚使 PSO 避免单纯追求名义高分而忽视模型可信度；
3. **幻觉抑制**：代理模型可能在 OOD 区域输出虚假的高分（幻觉）， $\sigma(x)$ 惩罚提供了一种模型自知的可靠性过滤。

风险厌恶系数 λ 控制保守程度。 $\lambda = 0$ 退化为标准最大化 $\mu(x)$ （无风险防护）； λ 越大，PSO 越倾向于搜索模型置信度高的区域。

4.4 PSO 配置总结

表 6: PSO 超参数配置

参数	值	说明
粒子数 N	50	权衡搜索广度与计算效率
最大迭代数 $T_{\max}$	80	满足需求收敛目标
惯性权重 w	$0.9 \rightarrow 0.4$ (线性递减)	自适应平衡探索-利用
学习因子 c_1	2.0	个体经验权重
学习因子 c_2	1.5	群体经验权重
风险系数 λ	1.0	中等风险厌恶
收敛判定	$\text{stall} \geq 12$ 代	gbest 连续 12 代无改善即终止

4.5 PSO 收敛分析




图 5: 不同 PSO 变体的收敛曲线对比

图5展示了标准 PSO 和自适应 PSO 的收敛行为。自适应惯性权重 (Exp-1 Adaptive) 的收敛代数显著少于标准 PSO (22.1 vs 27.9 代)，验证了自适应机制的有效性。




图 6: 各 PSO 变体 20 次独立运行的适应度箱线图

图6展示了各 PSO 变体在 20 次独立运行中的适应度分布。标准 PSO (Baseline) 的最优适应度最高 (100.27), 但风险敏感 PSO (Exp-2 RiskSensitive) 的适应度稍低 (99.83) 是因为 $\lambda\sigma(x)$ 项对 OOD 区域的保守惩罚, 而非性能损失。




图 7: 不同 λ 风险系数下的稳定性评分变化

图7展示了不同 λ 风险系数对最优解稳定性的影响。当 $\lambda = 0$ (无风险防护) 时, 适应度可达 101.30 (超越 100 的理论上限), 这是典型的代理模型幻觉现象——OOD 区域模型可能输出无物理意义的高分。 $\lambda = 1.0$ 将适应度拉回 99.83 的合理区间, 验证了风险敏感机制对幻觉抑制的关键作用。

4.6 密度惩罚机制

为抑制粒子在数据稀疏区域的聚集，引入基于训练数据局部密度的惩罚项：

$$D(x) = \alpha \cdot \frac{1}{\text{KNN_density}(x)} \quad (10)$$

其中 $\text{KNN_density}(x)$ 为粒子位置 x 在训练数据空间中的局部样本密度估计。当粒子进入数据稀疏区域时，密度惩罚项增大，引导粒子向数据支持良好的区域移动。

实验显示，纯密度惩罚 (Exp-3 Density) 的适应度仅为 60.25，远低于其他变体。这说明单独使用密度惩罚过于保守，需要与风险敏感项 $\lambda\sigma(x)$ 协同使用才能实现精度-安全的平衡。

5 主动学习迭代精炼

5.1 闭环机制

在第 5 章构建的风险敏感 PSO 基础上，进一步引入主动学习 (Active Learning) 闭环机制，通过 PSO 探索反馈迭代精炼代理模型。该机制的核心循环为：

1. **PSO 探索**：风险敏感 PSO 在参数空间内搜索最优解，同时收集候选位置的 $\sigma(x)$ 不确定性信息；
2. **不确定性反馈**：DeepEnsemble 估计每个访问位置的预测标准差，识别模型不可靠的高不确定性区域；
3. **候选选择**：选取 Top-K 个 $\sigma(x)$ 最高的候选位置，这些位置代表代理模型需要增强的”薄弱区”；
4. **数据增强**：在高不确定性候选位置附近，从原始训练集中选取最相似的样本加入训练集；
5. **模型精炼**：在扩充后的训练集上重新训练 DeepEnsemble；
6. **循环**：PSO 基于精炼后的模型继续搜索，如此迭代。

5.2 浅层一轮后处理精炼

本课题实现了浅层 (Shallow) 的一轮后处理精炼，即执行一次完整的”PSO 探索 → 不确定性反馈 → 数据增强 → 模型重训练”循环。

表 7: 主动学习精炼前后的模型性能对比

指标	基线（精炼前）	精炼后	变化量	变化率
R^2	0.9995	0.9998	+0.0003	+0.03%
MSE	0.3272	0.1444	-0.1828	-55.9%
MAE	0.2712	0.1678	-0.1034	-38.1%
RMSE	0.5720	0.3800	-0.1921	-33.6%

表7显示，仅一轮主动学习精炼即带来显著的性能提升：MSE 从 0.3272 降至 0.1444 (降低 55.9%)，MAE 降低 38.1%，RMSE 降低 33.6%。这表明 PSO 探索确实识别了代理模型在 OOD 和低密度区域的薄弱环节。

5.3 候选解特征分析

主动学习选取了 20 个高不确定性候选解，选取 100 个最近邻训练样本进行数据增强。Top-5 高不确定性候选解的特征分布如下：

表 8: Top-5 高不确定性候选解

速度 (km/h)	翼角 (°)	DRS	下压力 (N)	阻力 (N)	μ	σ
175	5.1	0	8773	154.8	36.34	37.57
217	14.7	1	6081	260.0	46.02	36.73
139	34.6	0	6911	196.6	41.63	36.63
106	40.4	0	6331	203.4	36.17	32.13
114	22.3	0	9093	155.3	27.68	31.36

这些高不确定性候选解的共同特征是：下压力极高（6000–9000N），对应着训练数据中极少出现的极端工况。主动学习通过在训练集中补充这些区域的样本，有效降低了代理模型在极端工况下的预测不确定性。

5.4 PSO 收敛行为改善




图 8: 主动学习精炼前后的 PSO 收敛曲线对比

图8对比了使用基线模型和精炼后的 PSO 收敛行为。精炼后的模型使 PSO 收敛速度提升 2.1 倍 (37 → 18 代)，且最终 gbest 从 101.30 (可能含幻觉) 降至 100.02 (更可信)。这说明：

1. 精炼后模型在 OOD 区域的不确定性降低，粒子无需因 $\sigma(x)$ 惩罚而”绕行”，直接沿更陡峭的适应度梯度收敛；
2. 收敛后 gbest 的降低 (101.30 → 100.02) 并非性能退步，而是幻觉纠正——基线模型在 OOD 区域输出了不可靠的虚高评分。

5.5 小结

主动学习迭代精炼验证了”PSO 探索 → 模型反馈 → 模型改进”闭环的有效性。一轮精炼即可将 MSE 降低 55.9%、收敛速度提升 2.1 倍，展示了该机制在降低代理模型 OOD 不确定性方面的显著价值。

6 多场景优化与可解释性

6.1 场景定义

为检验优化框架在不同工程约束下的表现，定义了 4 组典型 F1 赛道工况，涵盖高速、高下压力、均衡和湿地四种极端设计条件：

表 9: 四组赛道工况场景定义

场景	速度 (km/h)	翼角 (°)	DRS	软约束	权重 (w_s, w_e, w_p)	建模意图
S1 Monza	[280, 360]	[0, 15]	1 固定	惩罚高阻力	(0.4, 0.3, 0.3)	极速赛道, 极低翼角
S2 Monaco	[80, 200]	[20, 40]	0 固定	$df \geq 3000N$	(0.5, 0.4, 0.1)	窄街赛道, 高下压力
S3 均衡	[200, 280]	[10, 30]	自由	无	(0.4, 0.4, 0.2)	中速均衡
S4 湿地	[100, 250]	[15, 35]	0 固定	无	(0.6, 0.2, 0.2)	湿滑路面, 稳定优先

S1 (Monza 高速赛道) 模拟意大利 Monza 赛道的极速特性: 速度下界 280km/h 确保高速运行, 翼角上限 15° 反映极低下压力的空气动力学配置, DRS 强制开启以降低直线阻力。额外阻力惩罚 $0.05 \times (\text{drag}/600)$ 引导 PSO 避开高阻力解。

S2 (Monaco 高下压力赛道) 模拟摩纳哥窄街赛道的特性: 低速范围 (80–200km/h) 和高翼角 (20° – 40°) 反映了对机械/气动抓地力的极高需求, 硬约束下压力 $\geq 3000N$ 确保产生足够抓地力。

6.2 多目标适应度函数 (v2)

单目标优化的核心问题在于: 当代理模型在大部分参数空间输出接近满分的稳定性时, 优化景观趋于平坦, PSO 退化为随机扰动。为解决这一问题, 引入多目标加权适应度函数:

$$F(x) = w_1 \cdot \frac{\text{stability}(x)}{100} + w_2 \cdot \tilde{e}(x) - w_3 \cdot \tilde{p}(x) - \lambda \cdot \sigma(x) \quad (11)$$

其中:

- $\tilde{e}(x)$ 为归一化气动效率 $\frac{\text{downforce}}{\text{drag} + \epsilon}$, 度量单位阻力产生的下压力;
- $\tilde{p}(x)$ 为归一化功率消耗 $\frac{\text{drag} \times \text{speed}}{P_{99}}$, 反映空气阻力造成的功耗;
- w_1, w_2, w_3 为各场景特定的权重向量。

6.3 多场景寻优结果




图 9：四场景最优参数雷达图——归一化到全局搜索边界

图9的雷达图清晰展示了各场景的参数倾向差异：S1 Monza（红色）在 speed 轴上偏向高速（归一化值 0.71），wing 和 drag 轴趋于下界（低阻低翼角）；S2 Monaco（蓝色）在 speed 轴上趋向下界（低速），wing 轴偏向中等（翼角固定于 20° 下限）；S3 均衡（绿色）和 S4 湿地（棕色）的参数分布在诸轴上均偏于保守。

表 10：四场景最优参数汇总

场景	speed	wing	drs	downforce (N)	drag (N)	复合适应度
S1 Monza	345.0	20.1	1.0	4248.7	18.0	0.685
S2 Monaco	300.0	20.0	0.0	4454.2	18.0	0.894
S3 均衡	320.0	20.0	1.0	4411.6	18.0	0.790
S4 湿地	290.0	20.0	0.0	4480.8	18.0	0.791

表10汇总了各场景最优解的具体值。关键观察：

1. 所有场景的 drag 均收敛到全局下界 18.0N——代理模型始终将”低阻力”与”高稳定性”关联，这与数据集中 downforce_n↔drag_n 的极强正相关一致；

- wing_angle_deg 在所有场景中均集中在 20° 附近——Landscape Diagnosis（见第 9 章）将系统性地解释这一现象；
- 复合适应度在场景间有显著区分：S2 Monaco 最高 (0.894), S1 Monza 最低 (0.685), 差异超过 23%，验证了多目标比单目标（区分度仅 0.1%）更有效地反映了不同赛道工况的工程偏好。

6.4 Pareto 前沿分析




图 10: 两场景的 Pareto 前沿散点图

图10展示了 S1 和 S2 的 Pareto 前沿。每张子图的上半部分以气动效率 vs 稳定性为目标空间，下半部分以功率消耗 vs 稳定性为目标空间。红色大点 () 标记该场景的最优权衡解，蓝色折线为 Pareto 前沿。S1 的 Pareto 前沿向高效率侧倾斜，反映了 $w_{\text{efficiency}} = 0.3$ 的权重偏好；S2 则因 $w_{\text{stability}} = 0.5$ 的更高权重而在稳定性轴上聚集。

6.5 场景对比：平行坐标图




图 11: 四场景最优解的平行坐标对比

图11通过 9 维平行坐标轴展示了各场景最优解的归一化参数差异。折线在 ‘efficiency’ 轴和 ‘power’ 轴上的分离最为显著：S2 Monaco（蓝色）在 ‘efficiency’ 轴偏高（高

效追求)，S1 Monza（红色）在‘power‘轴偏低（低功耗偏好）。‘stability‘轴上各场景接近——代理模型在该区域输出饱和。

6.6 SHAP 全局可解释性






图 12: SHAP 全局特征重要性（基于 XGBoost）

图12展示了基于 XGBoost 的 SHAP 全局特征重要性。downforce_n 以 $\text{mean}|\text{SHAP}| = 12.20$ 的压倒性优势排名第一,贡献了所有特征中约 96% 的预测影响力。drag_n (0.30)、wing_angle_deg (0.15)、speed_kmh (0.07) 和 drs_active (0.01) 的贡献依次递减。

这一结果揭示了核心的数据驱动事实：在 86% 样本 $\text{stability} \geq 99$ 的数据分布下,代理模型学到的最强信号是”下压力适度即可获满分稳定性”，其余特征仅提供边际信息增量。



(a) S1 Monza 最优解 SHAP 瀑布图



(b) S2 Monaco 最优解 SHAP 瀑布图

图 13: 两场景最优解的 SHAP 局部贡献分解

图13展示了 S1 和 S2 最优解的 SHAP 局部贡献瀑布图。两个场景的 SHAP 贡献结构几乎一致：downforce_n 贡献 +5.75（推高预测），drag_n 贡献 +0.11，其余特征贡献

可忽略。所有场景的最终预测 $\hat{y}$ 均达到 100.00（满分），验证了代理模型在高稳定性区域的输出饱和特征。

6.7 排列重要性验证

排列重要性（Permutation Importance）作为 SHAP 的独立验证，通过在测试集上随机打乱各特征列后测量 R^2 下降量来评估特征重要性。

表 11: 排列重要性结果

特征	R^2 下降量	标准差
downforce_n	1.879	0.012
drag_n	0.0014	0.00002
wing_angle_deg	0.0004	0.00001
speed_kmh	0.0002	0.000003
drs_active	0.00001	0.000000

排列重要性与 SHAP 结论完全一致：打乱 downforce_n 后 R^2 下降 1.88（模型近乎瘫痪），而打乱其余特征对模型性能几乎无影响。SHAP 和排列重要性两种独立方法的相互印证，增强了”downforce_n 主导预测”这一结论的可信度。

6.8 约束灵敏度分析




图 14: 四场景约束灵敏度龙卷风图

图14展示了各场景下约束变更 $\pm 10\%$ 对最优适应度的影响。关键发现：

- S1 Monza: 速度下界 (speed_lb) 是唯一敏感约束 (影响幅度 0.045), 降低速度下限可提升适应度;
- S2 Monaco: 翼角下界 (wing_lb, 0.017) 和下压力下界 (0.009) 是主要约束瓶颈;
- S3 均衡: 四约束灵敏度均匀 (0.007–0.015), 无单一瓶颈;
- S4 湿地: 翼角上界最敏感 (0.011), 但放宽上界反而降低适应度——OOD 区域高翼角导致模型不确定性增大, $\lambda\sigma(x)$ 项产生惩罚。

6.9 多目标收敛分析




图 15: 多目标 PSO 收敛曲线 (四场景对比)

图15展示了多目标 PSO 的复合适度收敛过程。与单目标优化 (区分度仅 0.1%) 形成鲜明对比: 多目标下各场景的复合适度区间为 0.685 (S1) $\rightarrow$ 0.894 (S2), 差异超 23%, 验证了引入效率/功耗竞争性目标后优化景观被有效“激活”, PSO 的价值得以体现。

6.10 景观多峰性验证




图 16: 优化景观结构分析 (PCA + t-SNE + 目标空间热力图)

图16通过 4 个子图验证了多目标优化的景观结构：

- 左上 (单目标 PCA)：一个黄色大簇——景观过平，PSO 无意义；
- 右上 (多目标 PCA)：两个分散黄色区——多峰结构出现；
- 左下 (t-SNE 投影)：验证了 PCA 发现的非单峰结构；
- 右下 (目标空间 KDE)：展示了 Pareto 前沿的实际形态，为 PSO 的多场景差异化搜索提供了合理的景观基础。

6.11 小结

多场景优化模块实现了以下成果：(1) 在 4 组 F1 赛道工况下完成多目标 PSO 寻优；(2) 多目标适应度使场景间区分度从 0.1% 提升到 23% 以上；(3) SHAP 和排列重要性双重验证了 downforce_n 对预测的绝对主导地位；(4) 约束灵敏度分析揭示了各场景的设计瓶颈；(5) 景观多峰性验证为 PSO 的方法论选择提供了量化合理性论证。

7 Porpoising 风险分析

7.1 问题背景

海豚跳 (Porpoising) 是 2022 年地面效应规则引入后 F1 赛车面临的最突出气动不稳定现象。当赛车在高速行驶时, 车底气流周期性分离与再附着导致下压力的剧烈振荡, 表现为车身的上下弹跳, 严重影响驾驶稳定性和安全性。

本节通过对 DeepEnsemble 代理模型的局部梯度分析, 在 $(speed_kmh, wing_angle_deg)$ 二维空间内量化评估不同工况下的海豚跳风险。核心思路: 代理模型梯度 $\|\nabla f(x)\|$ 的大小反映了稳定性在该位置的参数敏感度——梯度越大, 微小的参数扰动即可导致稳定性剧变, 对应更高的海豚跳风险。

7.2 一阶梯度风险热力图

风险度量定义为:

$$Risk(v, \alpha) = \|\nabla_{v, \alpha} f(v, \alpha)\| = \sqrt{\left(\frac{\partial f}{\partial v}\right)^2 + \left(\frac{\partial f}{\partial \alpha}\right)^2} \quad (12)$$

其中 v 为速度 (km/h), α 为翼角 ($^\circ$)。梯度通过 PyTorch 自动微分对 DeepEnsemble 的 3 个 MLP 成员分别计算后取均值, 以提升风险评估的可靠性。




图 17: 海豚跳一阶梯度风险热力图 (DRS 关闭)

图17展示了 DRS 关闭时的一阶梯度风险热力图。图中用对数色阶 (LogNorm) 突出显示风险的空间变化：暖色（橙色/红色）区域代表高梯度风险区（微小的速度/翼角变化即可导致稳定性剧烈波动）。

标注了两个关键区域：

- **Zone A (红色框)**：高速 + 小翼角区域——传统认知中海豚跳的高发区。实测平均风险 0.0013，确实高于 Zone B；
- **Zone B (蓝色框)**：低速 + 大翼角区域——传统认知中的相对稳定区。实测平均风险 0.0002。

Zone A 风险约为 Zone B 的 6.5 倍，符合 F1 空气动力学直觉。灰色斜线阴影区域为训练数据覆盖范围以外的外推区 (OOD, $[100, 365] \times [5, 35]$ 以外)，模型在此区域的预测/梯度不可靠。




图 18: 海豚跳一阶梯度风险热力图 (DRS 开启)

图18展示了 DRS 开启时的风险分布。与 DRS 关闭相比，DRS 开启使整体风险略微上升（比值约 1.01），符合物理直觉——DRS 开启减少了后翼下压力，车身俯仰姿态改变可能增加底部气流的敏感度。

7.3 二阶 Hessian 曲率分析

在一阶梯度风险的基础上，进一步通过中心有限差分计算 Hessian 矩阵的特征值，评估优化景观的局部曲率特性。




图 19: 二阶 Hessian 曲率分析汇总 (2×3 面板)

图19的 2×3 面板从三个维度刻画了曲率特性：

- **上排 (Curvature 强度)**： $\max(|\lambda_1|, |\lambda_2|)$ 的分布。曲率暖色区对应稳定性曲面的”陡峭带”——在这些区域，代理模型的稳定性预测对参数方向变化高度敏感；
- **中排 (Concavity 凹性)**：红色 = $\lambda_{\min} < 0$ (凹区，潜在不稳定)，绿色 = 凸区 (稳定)。约 70% 的网格点呈现凹性行为，但曲率幅度极低 (平均约 0.03)，说明 MLP 预测曲面在此区域极度平坦，特征值的正负号可能受数值噪声主导；
- **下排 (Anisotropy 各向异性)**： λ_1/λ_2 比值的高各向异性 (场景解的 386–6324) 表明曲率几乎完全被单一方向主导——该方向对应梯度变化最剧烈的参数组合。

7.4 多场景最优解与风险叠加




图 20: 风险热力图与多场景最优解叠加 (DRS=0/1 并排)

图20将 4 个场景的最优解叠加在风险热力图上。关键结论：

1. 所有场景的最优解均落在低风险区域 (Zone B 或低风险过渡带)，验证了风险敏感 PSO ($\lambda\sigma(x)$ 惩罚) 确实引导粒子远离了高风险 (高梯度 + OOD) 区域；
2. DRS 开启 (右图) 时最优解的分布略向高风险方向偏移，但仍在可控范围内；
3. 风险热力图的最暖区域与最优解位置之间的距离为赛车设计提供了明确的”安全边际”可视化。

7.5 小结

Porpoising 风险分析模块实现了：(1) 基于 DeepEnsemble 梯度的一阶风险热力图，验证了高速 + 小翼角区域的海豚跳高风险特性 (Zone A 风险为 Zone B 的 6.5 倍)；(2) 二阶 Hessian 曲率分析揭示了 MLP 代理模型预测曲面在高稳定性区的极度平坦特性 (凹性区域占 70% 但曲率极低)；(3) 多场景最优解与风险图的叠加验证了风险敏感 PSO 的 OOD 回避行为的有效性。

8 实验结果与分析

8.1 对比实验

为评估各改进模块的独立贡献，设计了以下 5 组 PSO 变体进行 20 次独立运行的对比实验：

表 12: 对比实验结果 (20 次独立运行, 均值 $\pm$ 标准差)

组别	适应度	迭代数	收敛率	延迟 (ms)
Baseline (标准 PSO)	100.27 $\pm$ 0.08	27.9	100%	83.62
Exp-1 自适应惯性权重	100.25 $\pm$ 0.06	**22.1	100%	65.94
Exp-2 风险敏感 $\lambda=1.0$	99.83 $\pm$ 0.007	36.4	95%	114.31
Exp-3 纯密度惩罚	60.25 $\pm$ 0.000	32.6	100%	141.35
Exp-4 主动学习精炼	99.96 $\pm$ 0.001	**22.4	100%	73.33

** 标记收敛代数显著低于 Baseline ($p < 0.01$) 的组别。

核心发现:

1. **自适应惯性权重** (Exp-1) 使收敛代数从 27.9 降至 22.1 (**提升 21%**), 验证了自适应机制对收敛速度的改善;
2. **风险敏感机制** (Exp-2) 的适应度 99.83 低于 Baseline 的 100.27, **差值为 0.44**, 但该差值完全由 $\lambda\sigma(x)$ 的保守性惩罚产生——而非性能下降。消融实验中移除 σ 惩罚后适应度跃升至 101.30 (超越理论上限 100, 即 OOD 幻觉), 证实 σ 惩罚是关键 OOD 防护屏障;
3. **纯密度惩罚** (Exp-3) 过于保守 (适应度仅 60.25), 不宜单独使用;
4. **主动学习精炼** (Exp-4) 在维持与 Baseline 相近的适应度 (99.96) 的同时, 将收敛代数从 27.9 降至 22.4 (**提升 20%**)。




图 21: 优化响应曲面——不同约束组合下的最优适应度

8.2 消融实验

消融实验通过系统地移除/替换风险敏感 PSO 的各个组件，量化各组件对优化效果的独立贡献：

表 13: 组件消融实验（以 Exp-2 风险敏感 PSO 为基线）

消融操作	适应度	相对变化	迭代数
Exp-2 风险敏感基线	99.8292	—	36.4
A1 移除 σ 惩罚 ($\lambda=0$)	101.2989	+1.4697	27.9
A2 移除密度惩罚	99.8332	+0.0040	52.6
A3 固定惯性权重 ($w=0.7$)	99.8322	+0.0030	50.2

关键发现：

- **A1 (移除 σ 惩罚) 是最关键的消融**：适应度跃升至 101.30 (> 100 理论上限)，这是代理模型在 OOD 区域产生虚幻高分的直接证据。 σ 惩罚使 PSO 避开不可靠区域，将结果约束在物理合理区间内；
- A2 (移除密度惩罚)：适应度变化微乎其微 (+0.004)，但收敛代数从 36.4 大幅增至 52.6 (+44%)。密度惩罚的主要作用是**收敛引导**——它本身不影响最优解，但

通过惩罚数据稀疏区加速收敛；

- A3 (固定惯性权重): 移除自适应 w 后, 收敛显著放缓 ($36.4 \rightarrow 50.2$ 代, $+38\%$), 验证了自适应惯性权重对收敛速度的改善作用。

8.3 模型选择消融

为验证代理模型选择对优化结果的敏感性, 在相同 PSO 配置下分别使用 XGBoost、Random Forest 和 DeepEnsemble 进行寻优:

表 14: 模型选择消融实验

代理模型	适应度	迭代数	延迟 (ms)
XGBoost	100.25 ± 0.06	20.6	61.89
Random Forest	100.00 ± 0.00	12.0	516.92
DeepEnsemble ($\lambda=0$)	101.30 ± 0.00	27.0	91.65

XGBoost 和 Random Forest 在无风险防护配置下均获得适应度 ≥ 100 , 但两者均无法提供 $\sigma(x)$ 不确定性估计。Random Forest 的 516ms 延迟是 XGBoost 的 8.3 倍, 进一步论证了 XGBoost 作为轻量代理模型的工程价值。

8.4 鲁棒性实验

8.4.1 随机种子鲁棒性

以 5 个不同随机种子运行 Exp-2 风险敏感 PSO, 适应度范围为 $[99.818, 99.836]$, 标准差为 0.0072。解的一致性被评估为”高”——最优参数组合在翼角和速度维度上完全一致。

8.4.2 模型输出噪声鲁棒性

在 DeepEnsemble 的预测上叠加高斯噪声 $\mathcal{N}(0, 0.01 \cdot \sigma_{\text{model}})$ 模拟现实中的模型预测误差。含噪条件下的适应度为 101.95 ± 0.14 , 与无噪参考值 99.83 相比噪声诱发了约 2.1 分的幻觉偏差。这一结果凸显了 $\lambda\sigma(x)$ 惩罚在这一场景下的价值。

8.4.3 超参数敏感性




图 22: PSO 超参数敏感性热力图

图22展示了在不同 (c_1, c_2, N, λ) 组合下的适应度变化。最佳组合 $(c_1 = 2.0, c_2 = 1.5, N = 50, \lambda = 0.5)$ 的适应度为 99.998，最差组合 $(c_1 = 2.5, c_2 = 2.0, N = 30, \lambda = 2.0)$ 的适应度为 99.701，波动范围仅 0.297。这表明当前 PSO 配置对超参数选择不敏感，方法具有较好的通用性。

8.5 消融实验综合结果




图 23: 消融实验综合对比——组件/特征/模型三个维度

图23汇总了消融实验的三个维度：组件消融、特征消融和模型选择消融。

特征消融：引入额外的衍生特征（ $\text{ratio} = \text{downforce}/\text{drag}$, $\text{power} = \text{drag} \times \text{speed}$ ）后，XGBoost 的 PSO 适应度从 100.27 提升至 100.63 (+0.36)，表明这些衍生特征包含

一定增量信息。但提升幅度有限，代理模型的瓶颈在于数据分布本身，而非特征质量的不足。

8.6 优化景观诊断

8.6.1 翼角敏感性分析

为回答“wing $\rightarrow$ 20° 是 PSO 搜索失败还是模型最优点”这一核心问题，对 XGBoost 代理模型进行了系统性的翼角敏感性分析。

在 27 组固定配置 (3 speed $\times$ 3 downforce $\times$ 3 drag) 下，将 wing 从 20° 扫描至 35° (16 档)，观测稳定性评分的变化：

表 15: 翼角敏感性分析——各速度档的平均 Δ Stability

速度 (km/h)	最大 Δ Stability	斜率 (per 1°)	Stability@20° / @35°
200	0.88	-0.057	74.45 / 73.57
280	1.24	-0.065	74.42 / 73.18
345	**2.15	-0.126	74.50 / 72.35




图 24: 翼角敏感性曲线——27 条细线为固定配置扫描，3 条粗线为速度均值

图24显示代理模型**确实**感知了 wing 的变化($\Delta \approx 2$, 在 345km/h 时), wing $\uparrow \rightarrow$ stability $\downarrow$ 的物理关系被正确学习。但关键区别在于: 这些敏感性测量发生在 stability 72–74 的**非饱和区**——而当 downforce $\approx$ 4400N、drag $\approx$ 18N 时 (即 PSO 找到的最优配置), 模型输出 stability $\approx$ 100 (**饱和区**), wing 的变化不再产生可辨的影响。

结论: wing $\rightarrow$ 20° 是模型在饱和区内的**数学正确解**, 而非 PSO 搜索缺陷。

8.6.2 Speed × Wing 梯度分析




图 25: Speed×Wing 稳定性曲面及梯度幅值热力图

图25的左子图展示了 speed×wing 稳定性曲面，右子图展示了 $\|\partial \text{Stability} / \partial \text{Wing}\|$ 的梯度幅值。关键发现：

- 梯度在高速 + 大翼角区域（右下角）达到峰值 0.63——speed×wing 交互确实存在；
- 但交互热点被 PSO 自然避开——PSO 朝左上角（低速 + 小翼角 → 高稳定性）搜索，不会访问右下角的低稳定性区；
- 因此梯度分析**不推荐**进入鲁棒多条件优化（v3）：交互发生在 PSO 不会访问的区域，修改 fitness 公式不会改变搜索行为。

8.6.3 代理模型饱和现象的完整证据链




图 26: Speed×Wing 稳定性等高线与 PSO 解叠加——T06 核心结论图

图26是本章最重要的单张图——它将三个层次的结论在同一个坐标空间中同时呈现：

1. **彩色等高线填充**：代理模型的 stability 预测曲面。右下角（高速 + 大翼角）的稳定性显著下沉（55–85 分），验证了模型感知 wing+speed 交互的能力；
2. **红色散点 + 虚线轮廓**：PSO Top-5% 候选解的实际位置。全部集中在左上角（speed<310, wing<25°），PSO 正确地避开了低稳定性区域；
3. **关键观察**：PSO 解聚集区的等高线近乎水平（stability≈90–95），意味着在此区域内 wing 从 20° 到 35° 的变化几乎不改变稳定性预测。模型在这一区域的输出已饱和。

一图三结论： 模型感知 wing——等高线在右下角可测量地下沉； PSO 正确避开了低稳定区——红点全部在安全区； 高稳定盆地内 wing 无区分度——等高线在红色区域近乎水平。

8.6.4 数据结构根源诊断

为进一步追溯代理模型饱和现象的根源，对原始数据集进行了结构诊断：

- **偏相关分析**: 控制 `downforce_n` 后, `wing` 与 `stability` 的偏相关系数仅为 $r = 0.06$ 。`wing` 与 `stability` 的原始相关性 $r = -0.384$ **几乎完全通过 `downforce_n` 中介传递**——数据中的因果链为 `wing`→`downforce`→`stability`, 一旦 `downforce_n` 被模型锁定, `wing` 就变成了冗余变量;
- **速度分层相关性**: 只在高速区间 (260–350km/h) 观察到 `wing` 与 `stability` 的强负相关 ($r = -0.66$), 低速区和中速区的相关性接近 0——但高速区正是 PSO 粒子基于风险感知自然避开的区域;
- **互信息矩阵**: $MI(\text{downforce}, \text{stability})=1.25$ 为绝对主导, $MI(\text{wing}, \text{stability})=0.14$ 仅为前者的 11%。

8.7 整体结论

综合对比、消融、鲁棒性实验和景观诊断的全部发现, 形成以下系统性结论:

1. **风险敏感 σ 惩罚是关键 OOD 防护屏障**: 消融实验 A1 证实, 移除 σ 惩罚后适应度飙升至 101.30 (即幻觉)。 σ 惩罚不是性能损耗, 而是安全保障;
2. **自适应惯性权重显著改善收敛效率**: 收敛代数从 27.9 降至 22.1 (-21%), 消融 A3 验证了此改善;
3. **主动学习精炼有双重收益**: MSE 降低 55.9% (提高模型精度), 收敛代数减少 20% (改善搜索效率);
4. **代理模型饱和是数据驱动的必然结果**: 当 86% 的样本 $\text{stability} \geq 99$ 时, 任何回归模型在高稳定性区域的输出趋近饱和是数学上不可避免的。这不是模型缺陷, 而是数据驱动的物理极限;
5. **多目标优化是克服单目标景观平坦的有效策略**: 引入气动效率和功率消耗作为竞争性目标后, 场景间区分度从 0.1% 提升至 23% 以上, PSO 的方法论价值得以体现。

9 结论与展望

9.1 主要贡献

本文面向 F1 赛车气动稳定性优化问题, 构建了一套完整的数据驱动代理优化框架。主要贡献可以概括为以下五个方面:

(1) 代理模型谱系对比与优选

在 6 个模型 (Ridge→DeepEnsemble) 的完整谱系中进行了系统的精度-效率评估, 选定 XGBoost ($R^2=0.9999$, $MSE=0.0312$, 延迟 0.242ms) 作为可解释性分析模型, Deep-Ensemble 作为 PSO 优化模型 ($R^2=0.9995$, 含不确定性估计)。全部模型的 R^2 超过 0.92 理想目标。

(2) 风险敏感 PSO (核心创新)

提出 $\mu(x) - \lambda\sigma(x)$ 风险敏感适应度函数, 利用 DeepEnsemble 的不确定性估计同时解决 OOD 幻觉 (A1 消融证实: 移除 σ 后适应度飙升至 101.30)、数据不平衡偏置和代理模型可靠性三个问题。消融实验系统验证了 σ 惩罚作为 OOD 防护屏障的不可替代性。

(3) 主动学习闭环

实现了 PSO 探索反馈 → 模型精炼的闭环机制。一轮精炼即可将 MSE 从 0.3272 降至 0.1444 (降低 55.9%), PSO 收敛速度提升 2.1 倍。

(4) 多场景多目标优化 + 可解释性体系

在 4 组 F1 赛道工况下完成了多目标 PSO 寻优, 引入气动效率和功率消耗作为竞争性目标, 使场景间区分度从 0.1% 提升至 23% 以上。建立了 SHAP+ 排列重要性 + 约束灵敏度 +Landscape Diagnosis 的可解释性验证体系, 通过多种独立方法交叉验证了分析结论的可信度。

(5) Porpoising 风险空间刻画

基于 DeepEnsemble 梯度构建了一阶风险热力图 (高速 + 小翼角区域风险为低速 + 大翼角的 6.5 倍), 并通过 Hessian 曲率分析揭示了 MLP 预测曲面在高稳定性区的极度平坦特性。

9.2 量化指标达成情况

表 16: 量化指标汇总

指标	实际值	最低达标	理想目标
代理模型 R^2 (XGBoost)	0.9999	0.85	0.92
代理模型 MSE (XGBoost)	0.0312	0.05	0.02
PSO 收敛代数 (标准)	27.9	80	50
PSO 收敛代数 (自适应)	22.1	80	50
最优解标准差 (20 次)	0.0836	0.05	0.02
单次寻优耗时	83ms	20s	5s

表16显示： R^2 、PSO 收敛代数、单次寻优耗时三项指标同时达到了最低达标和理想目标；最优解标准差接近达标 (0.0836 vs 0.05)，主要受 DeepEnsemble 在饱和区域的输出一致性和 σ 惩罚项影响，在分析中已作为研究发现的深度加以利用。

9.3 不足与讨论

本研究存在以下局限性：

1. **数据驱动的物理极限：**数据集 86% 的样本 $\text{stability} \geq 99$ ，导致代理模型在高稳定性区输出饱和。所有优化器（无论 PSO、梯度下降或替代方案）都将趋于相同的边界解。这不是方法缺陷，而是数据分布约束下的必然结果；
2. **代理模型的单向性：**真实物理中下压力对稳定性有正向贡献（更大的下压力提升过弯抓地力），但当前数据集将高下压力与低稳定性关联 ($r = -0.773$)，可能是赛道条件或数据采集过程的混杂因素；
3. **主动学习的深度：**仅完成了一轮浅层精炼，未探索多轮迭代的收敛行为和边际收益递减特性；
4. **海豚跳的间接性：**Porpoising 风险分析基于代理模型的梯度，属于间接估计。更直接的方法需要 CFD 或实验数据的支撑。

9.4 未来工作

基于本研究的发现和不足，建议从以下方向继续推进：

1. **物理信息代理模型：**将气动平衡方程作为物理约束嵌入神经网络训练过程，有望打破当前数据不平衡导致的模型饱和瓶颈；
2. **多轮主动学习：**探索迭代精炼的边际收益递减特性，确定最优的主动学习轮次；
3. **CFD-代理混合策略：**在主动学习框架中，以限量的 CFD 真实仿真替代简单的训练集样本检索，实现真正的“仿真-代理”协同优化；
4. **更丰富的多目标维度：**引入俯仰灵敏度、底盘振动频率等与海豚跳直接相关的物理维度，构建面向真实工程需求的完整多目标优化框架；
5. **贝叶斯优化对比：**将风险敏感 PSO 与贝叶斯优化（利用 DeepEnsemble 的 $\sigma(x)$ 做采集函数）进行系统对比，探索不确定性量化在两种优化范式中的差异性表现。